

倒立摆连续控制中 Reward 延迟影响的分析

姓名：邓一骏

学号：25SD36037

2026 年 6 月 5 日

1 实验问题描述

1.1 任务背景

本实验以 Gymnasium 框架中的 Pendulum-v1 环境为研究对象，实现 Actor-Critic 和 DDPG 两种连续控制算法，使倒立摆稳定在竖直向上的平衡位置。实验要求：

1. 进行仿真，得到和在线教程同样的结果，并对结果进行比较分析；
2. 说清其中的 reward 是怎么取的。进一步，假设系统存在 5 个采样周期的延迟（reward 计算时只能使用 5 步之前的状态和输入值），重新进行仿真，输出仿真曲线，分析延迟对结果的影响。

1.2 环境定义

Pendulum-v1 的观测空间为 3 维连续向量 $[\cos \theta, \sin \theta, \dot{\theta}]$ ，其中 θ 为摆杆与竖直方向的夹角（ $\theta = 0$ 表示倒立平衡）。动作空间为 1 维连续量 $\tau \in [-2, 2]$ ，表示施加在摆杆上的电机力矩。每回合最大步数为 200 步。

2 Reward 机制与物理尺度说明

2.1 环境真实 Reward 公式

Pendulum-v1 的即时 reward 由 Gymnasium 内置公式定义：

$$r_{\text{true}} = -(\theta^2 + 0.1 \cdot \dot{\theta}^2 + 0.001 \cdot \tau^2) \quad (1)$$

其中 θ 为归一化角度偏差（ $\theta = 0$ 为最优，取值 $\theta \in [-\pi, \pi]$ ）， $\dot{\theta}$ 为角速度（取值范围 $[-8, 8]$ ）， τ 为控制力矩（ $\tau \in [-2, 2]$ ）。最大化 reward 等价于让摆杆稳定在竖直位置、减少摆动并降低控制能耗。

2.2 Reward 物理尺度分析

由于 reward 公式中含有平方项，不同策略下的 reward 数量级差异很大：

表 1: Pendulum-v1 中 Reward 的物理尺度分析

策略类型	典型单步 reward	200 步累计	物理含义
最优策略	≈ -0.6	≈ -120	$\theta \approx 0, \dot{\theta} \approx 0, \tau \approx 0$
随机策略	≈ -5.4	≈ -1080	$\theta, \dot{\theta}, \tau$ 均匀随机
劣化策略	≈ -7.6	≈ -1520	学到了推向远离平衡的错误动作

各分量贡献分析：

- 角度项 θ^2 : $\theta \in [-\pi, \pi]$, 随机时 $\mathbb{E}[\theta^2] = \pi^2/3 \approx 3.29$, 贡献约 3.29;
- 角速度项 $0.1\dot{\theta}^2$: $\dot{\theta} \in [-8, 8]$, 随机时 $\mathbb{E}[\dot{\theta}^2] = 64/3 \approx 21.33$, 贡献约 2.13;
- 力矩项 $0.001\tau^2$: $\tau \in [-2, 2]$, 随机时 $\mathbb{E}[\tau^2] = 4/3 \approx 1.33$, 贡献约 0.0013。

随机策略下单步 reward 约 $-(3.29 + 2.13 + 0.001) \approx -5.42$, 200 步累计约 -1084 。因此 -1170 的累计回报表明 Actor-Critic 学到的策略比随机更差——即策略梯度推向了错误的动作方向（如持续将摆杆拉离平衡位置），而这不难发生：对于基础 Actor-Critic, on-policy 更新的高方差使其在连续状态空间中容易陷入错误的局部最优。

2.3 延迟 Reward 实现

延迟 reward 的核心思想是：agent 在第 t 步收到的 reward 来自第 $t-d$ 步的状态和动作，而不是当前步的真实 reward。实现采用 FIFO 队列（图 1）。




图 1: 延迟 reward 实现机制

流程：

1. 环境以正常动力学推进，每步产生真实 reward r_{true} （式 (1)）；
2. 将当前步执行前的状态 s_t 和执行的动作 a_t 存入 FIFO 队列；

3. 若队列长度 ≤ 5 , 返回 $r_{\text{delay}} = 0$; 否则弹出 5 步前的记录, 用式 (1)重新计算 reward 返回 agent。`info["true_reward"]` 始终保存当前步真实 reward 用于评估。

3 实验设置

表 2: 超参数配置

参数	Actor-Critic	DDPG
训练回合数	120	100
Actor 学习率	3×10^{-4}	1×10^{-3}
Critic 学习率	1×10^{-3}	2×10^{-3}
隐藏层维度	128	128
折扣因子 γ	0.99	0.99
经验回放	无	100,000
批大小	—	64
预热步数	—	1,000
目标网络 τ	—	0.005

4 仿真结果与对比分析

4.1 与在线教程结果对比

以 Keras 官方 DDPG on Pendulum-v1 教程¹为基准。

表 3: DDPG 无延迟与 Keras 教程对比

指标	Keras 教程	本实验
初始 reward	≈ -1500	-1489.58 (第 10ep)
收敛速度	约 40-60 回合	第 31ep 达 -126.87, 第 39ep 达 -121.54
最终平滑 reward	-130 ~ -180	-118.36

本实验 DDPG 实现与教程趋势高度一致, 最终 -118.36 略优于教程基准, 说明实现正确。

¹https://keras.io/examples/rl/ddpg_pendulum/




图 2: 四组实验平滑真实回报对比

表 4: 四组实验结果汇总

实验	最终平滑 ($\bar{R}$)	最佳平滑	物理含义	收敛?
AC delay=0	-1240.14	-1170.03	比随机更差 (策略误导性收敛)	否
AC delay=5	-1261.85	-1173.58	比随机更差 (延迟加剧恶化)	否
DDPG delay=0	-118.36	-118.27	接近最优 ($\theta \approx 0, \tau \approx 0$)	是
DDPG delay=5	-125.86	-123.13	略逊于最优 (延迟引入 Q 值偏差)	是

4.2 DDPG 无延迟 vs 5 步延迟详细对比




图 3: DDPG 无延迟训练曲线




图 4: DDPG 延迟 5 步训练曲线

收敛速度： 无延迟在第 31ep 即达 -126.87 ；延迟 5 步要到第 53ep 才开始显著下降。延迟使探索时间增加约 70%。

最终性能： 无延迟 -118.36 vs 延迟 5 步 -125.86 ，下降约 6.3%。Critic 基于滞后信号拟合 Q 函数导致值函数偏差。

曲线形态： 无延迟曲线平滑单调下降；延迟 5 步前 52ep 在 -1500 和 -120 间反复跳跃，出现”探索-遗忘”现象。

4.3 Actor-Critic 失败分析

AC 在无延迟和延迟 5 步下均未收敛，累计回报 $-1170 \sim -1526$ （比随机策略 -1084 更差），原因：

1. **On-policy 高方差：** 单步 TD 误差方差大；
2. **无经验回放：** 每个 transition 只用一次；
3. **连续状态空间：** 策略梯度估计方差被进一步放大；

4. **错误收敛**：高斯策略的均值可能收敛到推出平衡位置的错误方向，导致比随机更差的回报。

4.4 DDPG 抗延迟鲁棒性

DDPG 在延迟下仍能收敛得益于其 off-policy 特性：经验回放允许从历史样本中重新学习；目标网络软更新确保学习目标不因延迟剧烈震荡；Critic 通过大量经验学到 reward 的统计规律。

5 结论

1. DDPG 无延迟收至 -118.36 ，与 Keras 教程一致且性能更优；
2. Reward 公式为 $r = -(\theta^2 + 0.1\dot{\theta}^2 + 0.001\tau^2)$ 。最优策略 -120 ，随机策略 -1080 ，据此可判断 AC 策略比随机更差 (-1240)；
3. 5 步延迟使 DDPG 收敛速度减慢 70%，性能下降 6.3%，但最终仍收敛；
4. AC 在两种条件下均不收敛，比随机策略更差的回报说明 on-policy 学习在高维连续空间中极易陷入错误局部最优；
5. DDPG 的 off-policy 机制对 reward 延迟具有天然鲁棒性。