

《深度强化学习与控制》第一周课程总结

邓一骏 25SD36037

May 2026

1、课程内容概述

本节课程围绕“强化学习与马尔可夫决策过程”这一主题展开，系统介绍了强化学习的基本概念、核心问题、数学建模方式以及典型求解思路。课程内容从强化学习与其他机器学习范式的区别出发，逐步引入序贯决策、智能体与环境交互、探索与利用、多臂老虎机问题、马尔可夫决策过程，以及值迭代和策略迭代等关键内容，构成了一条从直观理解到形式化建模、再到算法求解的完整知识链条。

通过本节课的学习，我对强化学习的认识不再停留在“让机器自己试错学习”的直观印象上，而是开始理解其背后的理论结构。尤其是马尔可夫决策过程作为强化学习数学基础的地位，以及 Bellman 思想在值函数更新中的核心作用，使我对后续强化学习算法的来源和逻辑有了更清晰的把握。可以说，这一讲不仅是强化学习课程的入门部分，也是后续深入学习 TD 方法、Q-learning、策略梯度和深度强化学习的重要理论起点。

2、强化学习的基本思想与任务特征

课程一开始区分了人工智能中的两类典型任务：预测型任务与决策型任务。预测型任务通常依赖已有数据进行模式学习，例如监督学习中的分类与回归、无监督学习中的聚类与生成；而决策型任务则要求智能体在动态环境中持续采取行动，并根据环境反馈不断调整行为策略。强化学习正是解决这类问题的典型方法。

与传统机器学习相比，强化学习最显著的特点在于“交互性”和“序贯性”。智能体不是在一个静态数据集上直接学习结论，而是在环境中不断观察、行动、获得奖励，并在长期试错中逐渐改善决策。课程中强调，**强化学习的目标不是单步最优，而是随着时间推移最大化累积奖励。这一目标设定意味着强化学习更关注长期效果，而不是局部收益最大化。**

这一点对我启发很大。许多现实问题之所以复杂，正是因为当前动作会影响未来状态，而未来状态又会进一步影响后续收益。比如自动驾驶、机器人控制、博弈决策、资源调度等场景，都不是“一步做对就结束”的问题，而是连续决策问题。**强化学习之所以重要，就在于它提供了一种能够处理这种长期依赖关系的学习框架。**

3、强化学习系统要素及其内在逻辑

在强化学习系统要素部分，课程介绍了历史、状态、策略、奖励、价值函数以及环境模型等概念。这些内容构成了理解强化学习的基础语言，也为后续 MDP 的形式化表达做了铺垫。

其中，状态是对历史信息的压缩表达，用来刻画“当前系统处于什么情形”；策略是从状态到动作的映射，表示智能体在特定状态下应采取怎样的行动；奖励则是环境对动作结果的即时反馈，用于告诉智能体当前行为是好还是坏。与奖励不同，价值函数关注的是长期意义上的优劣，它评估的是在某一状态下继续执行某个策略所能获得的期望累积回报。

我认为，这里最值得注意的是“奖励”和“价值”的区别。**奖励反映即时反馈，而价值反映长期收益。现实决策中，很多行为虽然短期看起来有利，但未必能带来长期最优结果。**强化学习之所以不同于简单的贪心方法，正是因为它通过价值函数把“眼前利益”和“未来影响”统一纳入考量。这种思路也让我更深刻地理解了为什么强化学习是一种面向长期目标的优化方法，而不仅仅是局部反应机制。

此外，课程还提到了环境模型的作用，即预测给定状态和动作后会出现什么下一个状态以及会得到什么奖励。虽然并非所有强化学习方法都显式使用模型，但模型这一概念有助于理解环境动态，也为后续基于模型的方法打下了认知基础。

4、探索与利用及多臂老虎机问题

探索与利用问题是强化学习中的经典矛盾。所谓“利用”，是指根据当前已有经验选择看起来最优的动作，以获得尽可能高的即时收益；所谓“探索”，则是尝试那些尚不确定但可能更优的动作，以积累信息、提升未来决策质量。两者之间的平衡直接影响学习效率和最终性能。

课程中通过多臂老虎机问题说明了这一矛盾的本质。多臂老虎机虽然没有复杂状态转移，因此被称为一种“无状态”的强化学习问题，但它集中体现了强化学习中最基本的决策难题：在不完全了解各动作收益分布的情况下，如何在尝试新选择与坚持当前优选之间做出权衡。课件总结中提到，epsilon-greedy 等方法在多臂老虎机问题中十分常用，而多臂老虎机也是研究探索与利用理论的重要环境 [10, 4]。

这一部分让我意识到，很多复杂强化学习算法的思想根源，其实都可以回溯到对探索策略的设计。即便在更高维、更复杂的环境中，智能体仍然面临“要不要尝试新的动作路径”的问题。换言之，探索与利用并不是某个单独章节里的概念，而是贯穿整个强化学习领域的主线问题。

5、马尔可夫决策过程的数学框架意义

本节课最核心的理论内容是马尔可夫决策过程，即 MDP。**马尔可夫过程和马尔可夫奖励过程 (MRP) 都是自发改变的随机过程；而如果有一个外界的“刺激”来共同改变这个随机过程，就有了马尔可夫决策过程 (MDP)。我们将这个来自外界的刺激称为智能体 (agent) 的动作，在马尔可夫奖励过程 (MRP) 的基础上加入动作，就得到了马尔可夫决策过程 (MDP)。**

MDP 的关键前提是马尔可夫性质，即当前状态已经足以概括未来演化所需的信息，不必依赖全部历史。这一性质使复杂的交互过程得以被抽象为在状态空间上的决策问题，从而大幅降低问题表达和求解的难度。课程进一步介绍了 MDP 的五元组表示，包括状态集合、动作集合、状态转移概率、奖励函数和折扣因子。通过这一形式化定义，强化学习问题不再只是“智能体不断试错”的口头描述，而是可以被严格分析的数学对象。

我对这一部分的理解是，MDP 的意义不仅在于“定义了环境”，更在于它建立了强化学习理论的共同语言。有了 MDP，才能进一步定义策略、价值函数、回报以及最优性准则；也正是在这

一框架下，Bellman 方程、动态规划方法以及后续各种强化学习算法才得以成立。因此，MDP 可以被看作强化学习理论体系的支柱。

6、值函数、折扣因子与长期回报

在 MDP 框架下，智能体的终极目标是找到一个最优策略，以最大化未来累积奖励的期望。为了在数学上定量评估这种面向未来的长远利益，课程首先引入了折扣因子 (γ) 来对未来奖励进行“折现”，并定义了单条轨迹的长期回报 (Return, G_t) 为：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \quad (1)$$

折扣因子的引入，让我认识到强化学习中的“最优”并非一成不变，而是与决策偏后有关。如果折扣因子较大，说明智能体更重视长期收益，甘愿为了长远布局而放弃眼前利益；如果折扣因子较小，则意味着其更倾向于即时回报。这种设计精妙地映射了现实中的投资、路径规划等决策逻辑——所有博弈的本质，都是在短期斩获与长期布局之间寻找一种动态平衡。然而，在实际计算中，我经历了一次思维的转变。由于环境的随机转移，从当前状态出发通往未来的路径往往会像树枝一样层层分叉。若要计算某个状态的价值 (Value, $V(s)$)，最直观的暴力方法是“正向路径展开”：找出所有可能走向终点的完整路径，将每条路径上各阶段的条件概率层层相乘得到路径总概率，再与该路径的累积回报相乘，最后进行加权求和（即求期望 $\mathbb{E}[G_t | S_t = s]$ ）。但这种正向穷举很快就会遭遇“维度灾难”，且概率交织极其复杂。此时，课程引出的贝尔曼方程 (Bellman Equation) 展示了另一种极其优雅的解题视角——“倒着算”的动态规划思想。贝尔曼方程将原本冗长的路径整体展开，巧妙地拆解为“眼前的即时奖励”与“下一步状态的折现价值”两部分：

$$V(s) = \sum_{a \in A} \pi(a | s) \sum_{s' \in S} P(s' | s, a) [R(s, a, s') + \gamma V(s')] \quad (2)$$

这种“倒着算”的机制让我豁然开朗：我们不再需要苦苦追踪每一条路径直到终点，而是可以从后脑勺（后续状态的已知价值 $V(s')$ ）一步步往前推。它利用重叠子问题的解，把通往无限未来的复杂回报，浓缩进了当前状态的一面“镜子”中。这不仅成功将“哪个状态更好”转化为可严密计算的数学问题，也为后续课程中值迭代和策略迭代的算法实现提供了最直接的递归基础。

7、值迭代与策略迭代的比较理解

在有限状态和有限动作的 MDP 中，课程介绍了两种经典求解方法：值迭代和策略迭代。值迭代的核心思想是直接利用 Bellman 最优方程不断更新各状态的价值估计，并通过贪心方式逐步逼近最优价值函数；策略迭代则分为策略评估和策略改进两个阶段，先评估当前策略的价值，再根据评估结果更新策略，反复进行直到收敛。

这两种方法虽然目标一致，但计算逻辑不同。值迭代更直接，强调通过不断迭代价值来隐式得到最优策略；策略迭代则更强调“先评估、再改进”的循环过程。根据课件中的比较，对于空间较小的 MDP，策略迭代通常收敛较快；而在空间较大时，价值迭代往往更具实用性。此外，如果不存在状态转移循环，价值迭代的适用性会更强。

通过这一部分学习，我更加深刻地体会到强化学习算法设计的本质并不只是“套公式”，而

是在统一理论框架下根据问题特征选择不同的优化路径。值迭代和策略迭代的比较不仅帮助我理解了动态规划方法本身，也让我意识到算法之间的差异往往来源于它们对“更新顺序”“计算代价”和“收敛方式”的不同处理。

8、老虎机中的强化学习算法对比

参考动手学强化学习 (<https://hrl.boyuai.com/>) 中多臂老虎机内容，对比四种经典多臂老虎机 (Multi-Armed Bandit) 算法：Epsilon-Greedy, Decaying Epsilon-Greedy, UCB, Thompson Sampling[2, 4] 在相同环境下的累积懊悔 (Cumulative Regret)，评估各算法的探索-利用平衡能力。表 1 展示了不同算法的核心思想与关键参数。

表 1: 多臂老虎机典型算法对比

算法	核心思想	关键参数
Epsilon-Greedy	以概率 ϵ 随机探索，以概率 $1 - \epsilon$ 贪心利用	$\epsilon = 0.01$ (固定)
Decaying Epsilon-Greedy	ϵ 随步数衰减 ($\epsilon = 1/t$)，早期多探索后期多利用	无
UCB	基于置信上界选择，兼顾均值与不确定性	$coef = 1$
Thompson Sampling	从 Beta 后验分布采样，依概率选择	无

8.1 形式化描述

多臂老虎机问题可以表示为一个元组 $\langle \mathcal{A}, \mathcal{R} \rangle$ ，其中：

- $\mathcal{A}$ 为**动作集合**：其中每一个动作表示拉动一个拉杆。若共有 K 根拉杆，则动作空间 $\mathcal{A} = \{a_1, \dots, a_K\}$ ，用 $a_t \in \mathcal{A}$ 表示第 t 步的动作。
- $\mathcal{R}$ 为**奖励概率分布**：拉动每一根拉杆 a 都对应一个奖励概率分布 $\mathcal{R}(r|a)$ ，不同拉杆的分布通常不同。

假设每个时间步只能拉动一个拉杆，MAB 的目标是最大化 T 步内的累积奖励： $\max \sum_{t=1}^T r_t$ ，其中 $r_t \sim \mathcal{R}(\cdot|a_t)$ 。

8.2 累积懊悔 (Cumulative Regret)

为了衡量决策的好坏，引入**懊悔 (Regret)** 概念。

- **期望奖励**： $Q(a) = \mathbb{E}_{r \sim \mathcal{R}(\cdot|a)}[r]$ 。
- **最优期望奖励**： $Q^* = \max_{a \in \mathcal{A}} Q(a)$ 。
- **单步懊悔**： $R(a) = Q^* - Q(a)$ ，即当前动作与最优动作之间的差距。

- **累积懊悔**: $\sigma_R = \sum_{t=1}^T R(a_t)$ 。

最大化累积奖励等价于最小化累积懊悔。

8.3 估计期望奖励与增量式更新

由于奖励具有随机性，需要通过多次采样来估计动作的期望奖励。对于动作 a ，其估计值 $\hat{Q}(a)$ 的更新流程如下：

1. **初始化**: 对于 $\forall a \in \mathcal{A}$ ，初始化计数器 $N(a) = 0$ ，期望奖励估值 $\hat{Q}(a) = 0$ 。
2. **迭代更新** (对于 $t = 1 \rightarrow T$):
 - 选取某根拉杆 a_t ，得到即时奖励 r_t 。
 - 更新计数器: $N(a_t) = N(a_t) + 1$ 。
 - 更新估值: $\hat{Q}(a_t) = \hat{Q}(a_t) + \frac{1}{N(a_t)} [r_t - \hat{Q}(a_t)]$ 。

8.3.1 增量式更新公式推导

采用增量式更新可以将空间复杂度从 $O(n)$ 降至 $O(1)$ 。推导过程如下：

$$\begin{aligned}
 Q_k &= \frac{1}{k} \sum_{i=1}^k r_i \\
 &= \frac{1}{k} \left(r_k + \sum_{i=1}^{k-1} r_i \right) \\
 &= \frac{1}{k} (r_k + (k-1)Q_{k-1}) \\
 &= \frac{1}{k} (r_k + kQ_{k-1} - Q_{k-1}) \\
 &= Q_{k-1} + \frac{1}{k} [r_k - Q_{k-1}]
 \end{aligned} \tag{3}$$

这种更新方式在计算上非常高效，因为它只需要存储当前的均值和步数。

8.4 10 臂老虎机流程图




图 1: 10 臂老虎机强化学习流程图

8.5 探索与利用的平衡

在多臂老虎机问题中，我们需要考虑的经典问题是探索与利用的平衡问题。探索 (exploration) 是指尝试拉动更多可能的拉杆，这根拉杆不一定会获得最大的奖励，但这种方案能够摸清所有拉杆的获奖情况。例如，对于一个 10 臂老虎机，我们要把所有的拉杆都拉动一下才知道哪根拉杆可能获得最大的奖励。利用 (exploitation) 是指拉动已知期望奖励最大的那根拉杆，由于已知的信息仅仅来自有限次的交互观测，所以当前的最优拉杆不一定是全局最优的。例如，对于一个 10 臂老虎机，我们只拉动过其中 3 根拉杆，接下来就一直拉动这 3 根拉杆中期望奖励最大的那根拉杆，但很有可能期望奖励最大的拉杆在剩下的 7 根当中，即使我们对 10 根拉杆各自都尝试了 20 次，发现 5 号拉杆的经验期望奖励是最高的，但仍然存在着微小的概率——另一根 6 号拉杆的真实期望奖励是比 5 号拉杆更高的。

于是在多臂老虎机问题中，设计策略时就需要平衡探索和利用的次数，使得累积奖励最大化。一个比较常用的思路是在开始时做比较多的探索，在对每根拉杆都有比较准确的估计后，再进行利用。目前已有一些比较经典的算法来解决这个问题，例如 ϵ -贪婪算法 (ϵ -Greedy)、Decaying Epsilon-Greedy 算法、上置信界算法 (UCB) 和汤普森采样算法 (Thompson Sampling) 等，接下来将分别介绍这几种算法。

完全贪婪算法即在每一时刻采取期望奖励估值最大的动作 (拉动拉杆)，这就是纯粹的利用，而没有探索，所以我们通常需要对完全贪婪算法进行一些修改，其中比较经典的一种方法为 ϵ -贪婪 (ϵ -Greedy) 算法。 ϵ -贪婪算法在完全贪婪算法的基础上添加了噪声，每次以概率 $1-\epsilon$ 选择以往经验中期望奖励估值最大的那根拉杆 (利用)，以概率 ϵ 随机选择一根拉杆 (探索)。随着探索次数的不断增加，我们对各个动作的奖励估计得越来越准，此时我们就没必要继续花大力气进行探索。所以在 ϵ -贪婪算法的具体实现中，我们可以令 ϵ 随时间衰减 (Decaying Epsilon-Greedy)，即探索的概率将会不断降低。简单地说，一个人去完成一个任务，前期肯定是摸索，当清楚局势后，他肯定会选择已知的，期望回报最高的路径，上述的 ϵ 就是探索的概率，前期设为 1 (乐观初始值，完全探索)，随着探索的加深，探索概率下降， $1-\epsilon$ (利用概率) 上升，所以 Decaying Epsilon-Greedy 算法比 ϵ -Greedy 算法更灵活且更符合人类的思维模式。Decaying Epsilon-Greedy 算法见图 2。




图 2: Decaying ϵ -greedy 算法流程图

设想这样一种情况：对于一台双臂老虎机，其中第一根拉杆只被拉动过一次，得到的奖励为 0；第二根拉杆被拉动过很多次，我们对它的奖励分布已经有了大致的把握。这时你会怎么做？或许你会进一步尝试拉动第一根拉杆，从而更加确定其奖励分布。这种思路主要是基于不确定性，因为此时第一根拉杆只被拉动过一次，它的不确定性很高。一根拉杆的不确定性越大，它就越具有探索的价值，因为探索之后我们可能发现它的期望奖励很大。我们在此引入不确定性度量，它会随着一个动作被尝试次数的增加而减小。我们可以使用一种基于不确定性的策略来综合考虑现有的期望奖励估值和不确定性，其核心问题是如何估计不确定性。上置信界（upper confidence bound, UCB）算法是一种经典的基于不确定性的策略算法，它的思想用到了一个非常著名的数学原理：霍夫丁不等式（Hoeffding's inequality）更直观地说，UCB 算法在每次选择拉杆前，先估计每根拉杆的期望奖励的上界，使得拉动每根拉杆的期望奖励只有一个较小的概率 p 超过这个上界，接着选出期望奖励上界最大的拉杆，从而选择最有可能获得最大期望奖励的拉杆。UCB 算法流程见图 3。

对比来看，两个算法在数学哲学上有本质差异。Decaying ϵ -Greedy 是一种全局的、盲目

的、随时间退化的探索。它对所有拉杆一视同仁，一旦决定了探索（哪怕概率只有 0.01%），它依然是闭着眼睛在 10 根杆里随机挑一根。它根本不记得哪根杆试得多，哪根杆试得少。上置信界算法 (UCB) 是一种个体的、理性的、基于不确定性的探索。如果某根杆 i 被冷落了 ($N(i)$ 很小)，会导致他的不确定性变得非常大，巨大的不确定性红利也会把它的总分“强行拉高”，从而诱骗计算机去拉它一把。它实现了真正的“精准扶贫”，永远倾向于给那些“了解不深、充满神秘感”的拉杆以机会，而不是像 ϵ -Greedy 那样不管三七二十一瞎猜。




图 3: UCB 算法流程图

MAB 中另一种兼具优雅与高效的经典算法是汤普森采样 (Thompson Sampling)。如果说 ϵ -Greedy 靠的是“掷硬币”，UCB 靠的是“死算置信区间”，那么汤普森采样靠的就是“心理对中奖率的预估分布”。该算法的核心思想是“用概率分布来表达对每根拉杆中奖率的猜测”。在决策时，为了避免直接计算复杂的全局期望奖励，汤普森采样采用了一种极其巧妙的“沙盘推演”机制：它直接根据每根拉杆当前的奖励概率分布进行一轮随机采样，为每根拉杆“摇出”一个虚拟的中奖率样本，随后果断选择样本值最大的那个动作。从统计学视角来看，这本质上是一种通过蒙特卡洛采样来近似求解各拉杆最优概率的贝叶斯方法 [1, 9]。

为了在游戏过程中动态调整对每根拉杆的“认知”，算法通常采用 Beta 分布来对二元奖励（中奖为 1，不中为 0）进行建模。具体而言，Beta 分布的参数天然对应着成功与失败的次数：若某根拉杆已被尝试 k 次，其中 m_1 次获得奖励 1， m_2 次获得奖励 0（满足 $m_1 + m_2 = k$ ），则该拉杆当前的奖励概率便服从参数为 $(m_1 + 1, m_2 + 1)$ 的 Beta 分布。这种设计使得算法能随着真实反馈的流入，自动在“探索未知”与“利用已知”之间达成完美的动态平衡。

那么如果实际问题中，拉杆不符合这个 beta 分布，这样模拟采样是不是没有意义的？进一步的了解到，经典的汤普森采样高度依赖 beta 分布的假设，如果现实世界的老虎机吐出来的不是 0 和 1，而是连续的钱（比如可能吐出 0.5 元、2 元、10 元），或者符合其他奇怪的分布，经

典的 Beta-TS 确实会直接失效。但有一个无脑但极度有效的 trick：**归一化 + 随机打平**。假设老虎机单次最高可能吐出 100 元。某一次你拉了杆，它吐出了 30 元。我们在代码里做一个映射：把 30 元看作是以 30% 的概率判定为“中奖 (1)”，70% 的概率判定为“没中 (0)”。扔个硬币，如果落在了 30% 区间，就给 Beta 分布的 α 加 1，否则给 β 加 1。汤普森采样的具体流程见图 4。。




图 4: Thompson Sampling 算法流程图

8.6 实验结果分析

表 2: 多臂老虎机典型算法累积懊悔对比

算法	累积懊悔	相对最优
Epsilon-Greedy	920.81	$98.70\times$
Decaying Epsilon-Greedy	9.33	基准
UCB	89.24	$9.56\times$
Thompson Sampling	59.26	$6.35\times$




图 5: Enter Caption

横轴：时间步（time steps）；纵轴：累积懊悔（越低越好）；理想形态：曲线早期快速上升（探索阶段），后期趋于平坦（进入利用阶段）Epsilon-Greedy 的曲线近似直线上升，说明其从未停止产生懊悔；而 Decaying Epsilon-Greedy 的曲线在约 1000 步后近乎水平，表明已收敛到最优策略。

1. Decaying Epsilon-Greedy 表现最优（懊悔 9.33） ϵ 随步数衰减的设计使其在早期充分探索、快速定位最优拉杆，后期完全利用，几乎不再产生额外懊悔。在 5000 步内近乎完美收敛。

2. Thompson Sampling 表现良好（懊悔 59.26）贝叶斯采样方法天然平衡探索与利用。虽不如衰减 ϵ 策略，但远优于固定 ϵ 策略，且无需手动调参。

3. UCB 表现中等（懊悔 89.24）理论上 UCB 有 $O(\log T)$ 的懊悔上界。当前 coef=1 可能偏保守，适当调整系数可进一步优化。

4. Epsilon-Greedy 表现最差（懊悔 920.81）固定 $\epsilon=0.01$ 意味着每一步都有 1% 的概率随机探索且永不衰减—累计 5000 步约 50 步浪费在无效探索上。这是”永远在探索、无法充分利用”的典型反例，这应证了 8.4 节中对于 Epsilon-Greedy 和 Decaying Epsilon-Greedy 的讨论。

9、四类算法缺陷与改进

9.1 Epsilon-Greedy 缺陷

1. 固定 ϵ 永不衰减

理论上懊悔线性增长：

$$R(T) \approx \varepsilon T \cdot \Delta \quad (4)$$

其中 Δ 为平均奖励差距。实验中 $\varepsilon = 0.01$ 时 5000 步懊悔约 920，近似一条直线。无论跑多少步，永远有 1% 的概率选到次优臂，永不收敛。

2. 探索完全盲目

ε 概率下在所有臂上均匀随机选择，好的次优臂和差的次优臂被选中的概率一样，浪费了大量尝试在明显很差的臂上。

3. 最优 ε 依赖先验知识

$\varepsilon = 0.1$ 和 $\varepsilon = 0.01$ 的性能差异巨大，但哪个好取决于环境。实际中并不知道最优 ε 是多少。

9.2 改进

表 3: Epsilon-Greedy 改进方案

改进方案	核心思想	解决问题
Decaying ε	$\varepsilon = 1/t$	懊悔 $O(\log T)$, 永不收敛 $\rightarrow$ 收敛
Softmax Exploration	Boltzmann 分布选探索臂	盲目探索 $\rightarrow$ 加权探索
Annealing Softmax	ε 衰减 + Softmax	综合两者优势
Exp3	权重指数更新	扩展到对抗性环境

9.3 Decaying Epsilon-Greedy 缺陷

1. 衰减速度固定，未必最优

$\varepsilon = 1/t$ 只是一个启发式的数值。如果最优臂和次优臂差异极小（如 0.72 vs 0.71），早期探索不够，会过早锁定次优臂。实验中它幸运地早期就找到了最优臂（懊悔 9.33），但换一个随机种子可能表现截然不同。

2. 仍然盲目探索

虽然 ε 衰减了，但在探索时仍然是均匀随机，没有利用已有的信息。

3. 理论下界不如 UCB

最优理论懊悔下界是 $O(\log T)$ ，Decaying ε 能达到，但常数因子比 UCB 大。

9.4 改进

表 4: Decaying Epsilon-Greedy 改进方案

改进方案	核心思想
自适应衰减率	根据观测到的奖励方差动态调整 ε
$\varepsilon = \min(1, cK/d^2t)$	根据臂数 K 和奖励差距 d 设置衰减系数
结合置信区间	探索时只选置信区间宽的臂，而非所有臂

9.5 UCB (Upper Confidence Bound) 缺陷

1. 过于乐观 (乐观 bias)

UCB 给每个臂加一个“置信上界”，天生倾向选择“不确定性高”的臂。对于较差但尚未充分探索的臂，UCB 可能会反复尝试。

2. coef 参数敏感

理论上 $\text{coef} = 0.5$ 或 1 有理论保证，但在有限步数下未必最优。 coef 过小 $\rightarrow$ 探索不足； coef 过大 $\rightarrow$ 过度探索。

3. 不适用于非平稳环境

传统 UCB 假设奖励分布固定不变。如果某个臂的奖励概率随时间变化（如推荐系统中用户偏好漂移），UCB 无法适应。

4. 忽略了奖励方差

只用了均值估计和尝试次数，没有考虑每次奖励的波动大小。方差大的臂应该探索更多。

9.6 改进

表 5: UCB 改进方案演进

改进方案	核心思想	发表
UCB1-Tuned	引入方差估计，代替 $\sqrt{\ln t/n}$	Auer et al., 2002 [3]
UCB-V	Chernoff-Hoeffding 界的方差感知版本	Audibert et al., 2009 [5]
MOSS	置信项 $\sqrt{\frac{\ln(T/n)}{n}}$ ，Minimax 最优	Audibert & Bubeck, 2009 [5]
KL-UCB	用 KL 散度代替 Hoeffding 界，更紧置信区间	Garivier & Cappé, 2011 [6]
Bayes-UCB	后验分位数构造置信上界	Kaufmann et al., 2012 [8]
SW-UCB	滑动窗口机制适应非平稳环境	Garivier & Moulines, 2011 [7]
Discounted UCB	历史奖励加指数衰减权重	Kocsis & Szepesvári, 2006

9.7 Thompson Sampling 缺陷

1. 理论收敛证明来得晚

虽然 1933 年就提出，但直到 2010 年代才被证明达到 $O(\log T)$ 最优懊悔。很长一段时间人们认为它“效果好但说不清为什么”。

2. 仅适用于可采样后验的分布

传统 TS 要求奖励分布是共轭先验族 (Beta-Bernoulli、Gaussian-Gaussian)。对于复杂奖励 (如深度学习特征)，后验难以直接采样。

3. 计算开销相对较大

每一步都要从 K 个 Beta 分布采样。在小规模场景问题不大，但大规模场景有成本。

4. 对先验敏感

代码中先验是 Beta(1,1) (均匀分布)，但如果先验设置不当，初期决策可能很差。

9.8 改进

表 6: Thompson Sampling 改进方案

改进方案	核心思想	发表
Generalized TS	Langevin Monte Carlo / 变分推断近似后验	多篇
Bootstrapped TS	Bootstrap 重采样代替精确后验采样	Eckles & Kaptein, 2014
Deep / Neural TS	神经网络提取特征 + TS 决策	Riquelme et al., 2018 [11]
PACTS	近似采样保证高效计算	—
共轭先验适配	Poisson、Exponential 等共轭先验设计	—

10、算法演进全景

年份	里程碑
1952	Epsilon-Greedy (最早、最简单)
1985	Softmax / Boltzmann 探索
2002	UCB1 (Auer 等人)
2009	UCB-V, MOSS (Minimax 最优)
2011	KL-UCB, SW-UCB (非平稳)
2012	Bayes-UCB
1933–2010s	Thompson Sampling → 最优证明
2018	Neural TS / 深度 Bandit
2020s	上下文 Bandit, 离线 Bandit, LLM + Bandit

图 6: 多臂老虎机算法演进史

11、总结：场景与算法选择

表 7: 不同场景下的算法推荐

场景	推荐算法	原因
快速原型、简单场景	Decaying ε -Greedy	简单、无参数、效果够好
理论严谨、后悔可控	UCB / KL-UCB	最优理论保证
通用稳健、无需调参	Thompson Sampling	效果好、自适应、贝叶斯解释
大规模推荐系统	Neural TS / 上下文 Bandit	结合深度特征
非平稳环境	SW-UCB / Discounted UCB	自适应遗忘历史
对抗性环境	EXP3	无随机假设

参考文献

- [1] W. R. Thompson. *On the Likelihood that One Unknown Probability Exceeds Another in View of the Evidence of Two Samples*. Biometrika, 25(3/4):285–294, 1933.
- [2] T. L. Lai and H. Robbins. *Asymptotically Efficient Adaptive Allocation Rules*. Advances in Applied Mathematics, 6(1):4–22, 1985.
- [3] P. Auer, N. Cesa-Bianchi, and P. Fischer. *Finite-time Analysis of the Multiarmed Bandit Problem*. Machine Learning, 47(2):235–256, 2002.
- [4] S. Bubeck and N. Cesa-Bianchi. *Regret Analysis of Stochastic and Nonstochastic Multi-armed Bandit Problems*. Foundations and Trends in Machine Learning, 5(1):1–122, 2012.
- [5] J.-Y. Audibert and S. Bubeck. *Minimax Policies for Adversarial and Stochastic Bandits*. In COLT, 2009.
- [6] A. Garivier and O. Cappé. *The KL-UCB Algorithm for Bounded Stochastic Bandits*. In COLT, 2011.
- [7] A. Garivier and E. Moulines. *On Upper-Confidence Bound Policies for Non-stationary Bandit Problems*. In ALT, 2011.
- [8] E. Kaufmann, O. Cappé, and A. Garivier. *On Bayesian Upper Confidence Bounds for Bandit Problems*. In AISTATS, 2012.
- [9] D. Russo, B. Van Roy, A. Kazerouni, I. Osband, and Z. Wen. *A Tutorial on Thompson Sampling*. Foundations and Trends in Machine Learning, 11(1):1–96, 2018.
- [10] A. Slivkins. *Introduction to Multi-Armed Bandits*. Foundations and Trends in Machine Learning, 2019.

- [11] C. Riquelme, G. Tucker, and J. Snoek. *Deep Bayesian Bandits Showdown: An Empirical Comparison of Bayesian Deep Networks for Thompson Sampling*. In ICLR, 2018.